1 Описание проекта

Допустим, вы работаете в добывающей компании «ГлавРосГосНефть». Нужно решить, где бурить новую скважину.

Вам предоставлены пробы нефти в трёх регионах: в каждом 10 000 месторождений, где измерили качество нефти и объём её запасов. Постройте модель машинного обучения, которая поможет определить регион, где добыча принесёт наибольшую прибыль. Проанализируйте возможную прибыль и риски.

Шаги для выбора локации:

- В избранном регионе ищем месторождения, для каждого определяем значения признаков;
- Строим модель и оцениваем объём запасов;
- Выбираем месторождения с самым высокими оценками значений. Количество месторождений зависит от бюджета компании и стоимости разработки одной скважины;
- Прибыль равна суммарной прибыли отобранных месторождений

2 Задача

1. **Построить модель для определения региона, где добыча принесёт наибольшую прибыль.**
2. **Проанализировать возможную прибыль и риски.**

3 Загрузка и подготовка данных

В [2]:

```
# импорт данных
import os
from urllib.request import urlretrieve
from IPython.display import display
from pathlib import Path
import urllib


# Основные библиотеки для работы с данными
import pandas as pd
import numpy as np

# работа с графиками
from matplotlib import pyplot as plt
import seaborn as sns
from IPython.display import display
from PIL import Image

# библиотека для модели
from sklearn.linear_model import LinearRegression

# Настройка моделей и параметров (разбивка датасета, его перемешивание и т.д.)
from sklearn.model_selection import train_test_split
from sklearn.model_selection import GridSearchCV
from tqdm import tqdm
from itertools import product

# Наши основные показатели
from sklearn.preprocessing import StandardScaler
from sklearn.metrics import mean_squared_error

from scipy import stats as st
from scipy.stats import t
from numpy.random import RandomState
import urllib
import urllib.request

```

executed in 1.03s, finished 12:49:19 2021-08-16

В [3]:

```
# отключение предупреждений
import warnings; warnings.filterwarnings("ignore", category=Warning)
```

executed in 5ms, finished 12:49:19 2021-08-16

В [4]:

```
# обновление библиотек Numpy и Pandas для исключения ошибок версий
# !pip3 install --upgrade --user --quiet --no-warn-script-location numpy==1.20.1 pandas
```

executed in 12ms, finished 12:49:19 2021-08-16

В [5]:

```
# для просмотра всех столбцов таблицы
pd.options.display.max_columns = None
```

executed in 11ms, finished 12:49:19 2021-08-16

В [6]:

```
# # обновление библиотек
# !pip3 install --upgrade --user --quiet matplotlib seaborn
```

executed in 13ms, finished 12:49:19 2021-08-16

В [7]:

```
# # обновление библиотек
# !pip3 install --upgrade --user --quiet sklearn
```

executed in 8ms, finished 12:49:19 2021-08-16

3.1 Загрузка данных

В [8]:

```
def load_from_url(file_url, file_path):
    """Загрузка файла из сетевого источника и загрузка в file_path"""
    folder_path = os.path.dirname(file_path)
    if not os.path.exists(folder_path):
        print('Создаем папку {folder_path}')
        os.makedirs(folder_path)
        print(f'Закгружаю файл из "{file_url}" в "{file_path}" ... ', end='')
        result = urllib.urlretrieve(url=file_url, filename=file_path)
        print('OK')
        return result


```

executed in 9ms, finished 12:49:19 2021-08-16

В [9]:

```
def get_data_frame(file_path, *args, **kwqrgs):
    """Загружаю файл из локального файла file_path"""
    print(f'Открываю "{file_path}" с помошью Pandas ...', end='')
    result = pd.read_csv(file_path, *args, **kwqrgs)
    print('OK')
    return result

```

executed in 12ms, finished 12:49:19 2021-08-16

В [10]:

```
#
def load_dataframe(file_url, file_path, *args, **kwqrgs):
    if os.path.isfile(file_path):
        print(f'Файл "{file_path}" уже был ранее заргужен.')
    else:
        load_from_url(file_url, file_path)
#     Создаем датафрейм
    return get_data_frame(file_path, *args, **kwqrgs)

```

executed in 7ms, finished 12:49:19 2021-08-16

В [11]:

```
dataset_url0 = 'https://code.s3.yandex.net/datasets/geo_data_0.csv'
dataset_url1 = 'https://code.s3.yandex.net/datasets/geo_data_1.csv'
dataset_url2 = 'https://code.s3.yandex.net/datasets/geo_data_2.csv'

dataset_path0 = 'D:/projects/geo_data_0.csv'
dataset_path1 = 'D:/projects/geo_data_1.csv'
dataset_path2 = 'D:/projects/geo_data_2.csv'
```

executed in 14ms, finished 12:49:19 2021-08-16

В [12]:

```
raw_data0 = load_dataframe(dataset_url0, dataset_path0)
raw_data1 = load_dataframe(dataset_url1, dataset_path1)
raw_data2 = load_dataframe(dataset_url2, dataset_path2)
```

executed in 536ms, finished 12:49:19 2021-08-16

```
Файл "D:/projects/geo_data_0.csv" уже был ранее заргужен.
Открываю "D:/projects/geo_data_0.csv" с помошью Pandas ...OK
Файл "D:/projects/geo_data_1.csv" уже был ранее заргужен.
Открываю "D:/projects/geo_data_1.csv" с помошью Pandas ...OK
Файл "D:/projects/geo_data_2.csv" уже был ранее заргужен.
Открываю "D:/projects/geo_data_2.csv" с помошью Pandas ...OK
```

3.2 Описание данных и подготовка к анализу

- id — уникальный идентификатор скважины;
- f0, f1, f2 — три признака точек;
- product — объём запасов в скважине (тыс. баррелей).

В [13]:

```
# Делаем функцию которая будет описывать данные для каждого датафрейма
def data_analysis(loc, name):
    print(name + '\n' + '-' * 50)
    loc.info()
    print('-' * 50)
    print('head()')
    display(loc.head(3))
    print('-' * 50)
    print('nunique()')
    display(loc.nunique())
    print('-' * 50)
    print('Полных дубликатов -', loc.duplicated().sum())
    print('-' * 50)
    print('describe()')
    display(loc.describe().transpose())
    print('-' * 50)
    print('corr()')
    display(loc.corr())
    g=sns.pairplot(loc)
    g.fig.suptitle(f'Распределения и зависимости признаков в регионе "{name}"', y=1.08)
    print()
```

executed in 8ms, finished 12:49:19 2021-08-16

3.2.1 Регион №1

B [14]:

```
1  data_analysis(raw_data0, 'Well1')
```

executed in 6.08s, finished 12:49:25 2021-08-16

```
Well1
-------------------------------------------------
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 100000 entries, 0 to 99999
Data columns (total 5 columns):
 #   Column   Non-Null Count   Dtype  
---  ------   --------------   -----  
 0   id       100000 non-null  object 
 1   f0       100000 non-null  float64
 2   f1       100000 non-null  float64
 3   f2       100000 non-null  float64
 4   product  100000 non-null  float64
dtypes: float64(4), object(1)
memory usage: 3.8+ MB
-------------------------------------------------
head()
```

	id	f0	f1	f2	product
0	txEyH	0.705745	-0.497823	1.221170	105.280062
1	2acmU	1.334711	-0.340164	4.365080	73.037750
2	409Wp	1.022732	0.151990	1.419926	85.265647

```
-------------------------------------------------
nunique()

id          99990
f0         100000
f1         100000
f2         100000
product    100000
dtype: int64

-------------------------------------------------
Полных дубликатов - 0
-------------------------------------------------
describe()
```

	count	mean	std	min	25%	50%	75%	m
f0	100000.0	0.500419	0.871832	-1.408605	-0.072580	0.502360	1.073581	2.3623
f1	100000.0	0.250143	0.504433	-0.848218	-0.200881	0.250252	0.700646	1.3437
f2	100000.0	2.502647	3.248248	-12.088328	0.287748	2.515969	4.715088	16.0037
product	100000.0	92.500000	44.288691	0.000000	56.497507	91.849972	128.564089	185.3643

```
-------------------------------------------------
corr()
```

	f0	f1	f2	product
f0	1.000000	-0.440723	-0.003153	0.143536

	f0	f1	f2	product
f1	-0.440723	1.000000	0.001724	-0.192356
f2	-0.003153	0.001724	1.000000	0.483663
product	0.143536	-0.192356	0.483663	1.000000

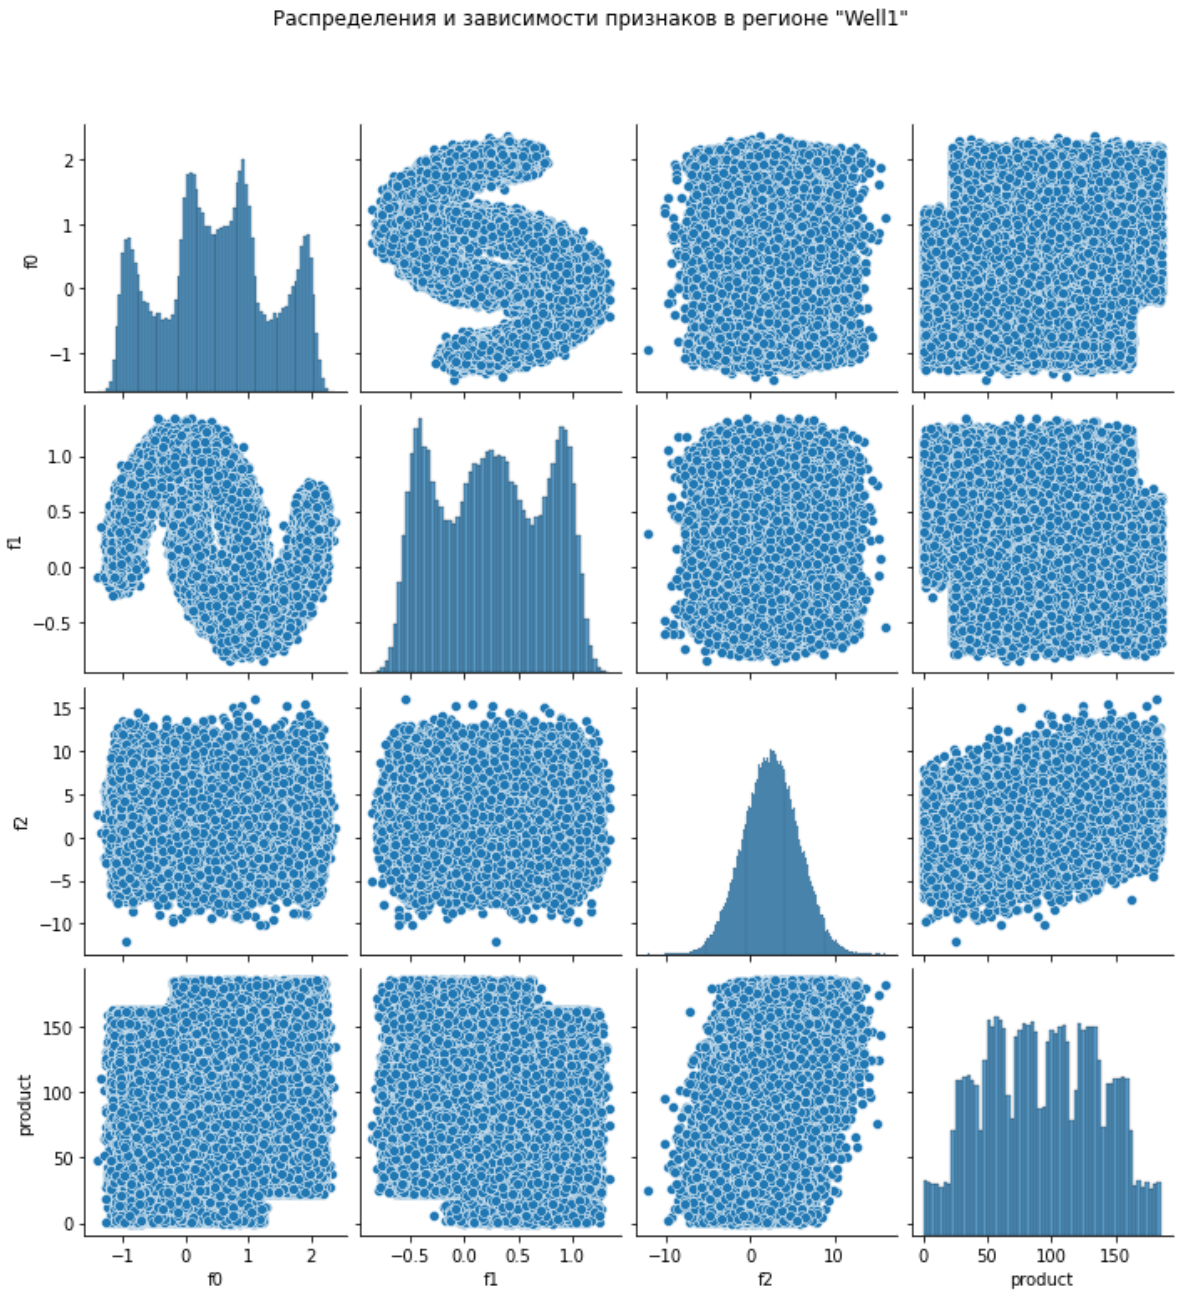

3.2.1.1 Вывод по региону 1

Данные нормальные. Нет пропусков и дубликатов. Также не видно сильных аномалий

3.2.2 Регион №2

B [15]:

```
1 data_analysis(raw_data1, 'Well2')
```

executed in 5.65s, finished 12:49:31 2021-08-16

```
Well2
-------------------------------------------------
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 100000 entries, 0 to 99999
Data columns (total 5 columns):
 #   Column   Non-Null Count   Dtype  
---  ------   --------------   -----  
 0   id       100000 non-null  object 
 1   f0       100000 non-null  float64
 2   f1       100000 non-null  float64
 3   f2       100000 non-null  float64
 4   product  100000 non-null  float64
dtypes: float64(4), object(1)
memory usage: 3.8+ MB
-------------------------------------------------
head()
```

	id	f0	f1	f2	product
0	kBEdx	-15.001348	-8.276000	-0.005876	3.179103
1	62mP7	14.272088	-3.475083	0.999183	26.953261
2	vyE1P	6.263187	-5.948386	5.001160	134.766305

```
-------------------------------------------------
nunique()

id          99996
f0         100000
f1         100000
f2         100000
product        12
dtype: int64


-------------------------------------------------
Полных дубликатов - 0
-------------------------------------------------
describe()
```

	count	mean	std	min	25%	50%	75%	m
f0	100000.0	1.141296	8.965932	-31.609576	-6.298551	1.153055	8.621015	29.4217
f1	100000.0	-4.796579	5.119872	-26.358598	-8.267985	-4.813172	-1.332816	18.734(
f2	100000.0	2.494541	1.703572	-0.018144	1.000021	2.011479	3.999904	5.0197
product	100000.0	68.825000	45.944423	0.000000	26.953261	57.085625	107.813044	137.945(

```
-------------------------------------------------
corr()
```

	f0	f1	f2	product
f0	1.000000	0.182287	-0.001777	-0.030491
f1	0.182287	1.000000	-0.002595	-0.010155
f2	-0.001777	-0.002595	1.000000	0.999397
product	-0.030491	-0.010155	0.999397	1.000000

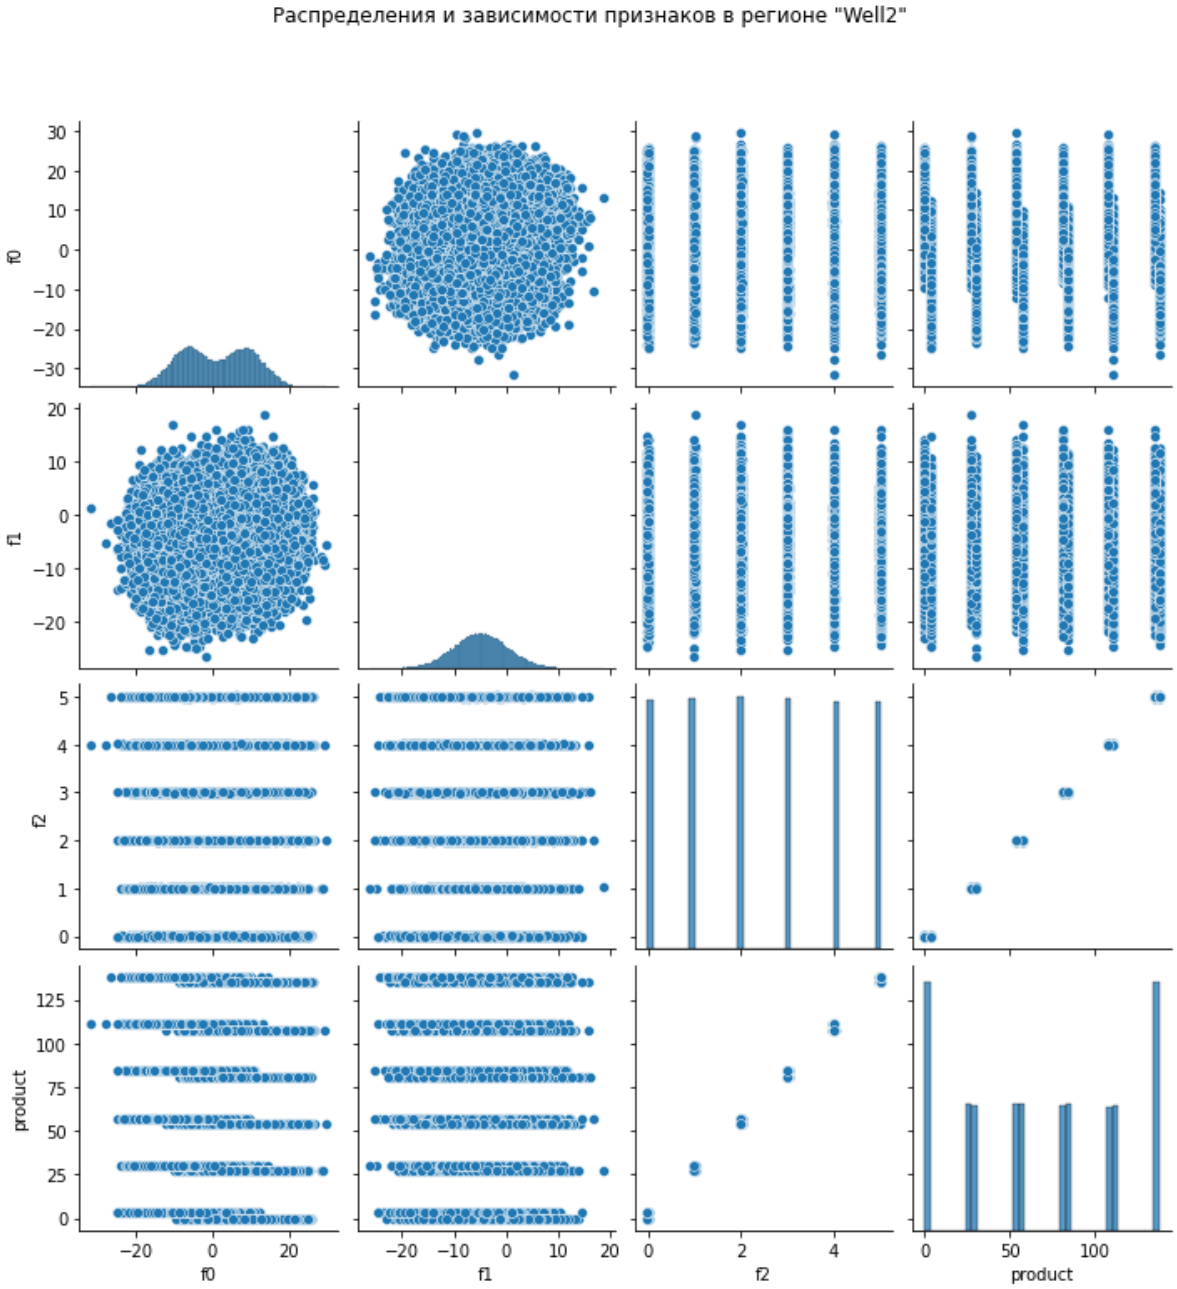

3.2.2.1 Вывод по региону 2

Данные нормальные. Нет пропусков и дубликатов. Не видно сильных аномалий.

Также есть интересная особенность параметр f2 очень сильно коррелирует с цеелвым признаком. Далее мы попробуем только на этом признаке обучить модель, посмотрим что из этого получится.

3.2.3 Регион №3

B [16]:

```
1  data_analysis(raw_data2, 'Well3')
```

executed in 6.57s, finished 12:49:38 2021-08-16

```
Well3
-------------------------------------------------
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 100000 entries, 0 to 99999
Data columns (total 5 columns):
 #   Column   Non-Null Count   Dtype
---  ------   --------------   -----
 0   id       100000 non-null  object
 1   f0       100000 non-null  float64
 2   f1       100000 non-null  float64
 3   f2       100000 non-null  float64
 4   product  100000 non-null  float64
dtypes: float64(4), object(1)
memory usage: 3.8+ MB
-------------------------------------------------
head()
```

	id	f0	f1	f2	product
0	fwXo0	-1.146987	0.963328	-0.828965	27.758673
1	WJtFt	0.262778	0.269839	-2.530187	56.069697
2	ovLUW	0.194587	0.289035	-5.586433	62.871910

```
-------------------------------------------------
nunique()

id          99996
f0         100000
f1         100000
f2         100000
product    100000
dtype: int64

-------------------------------------------------
Полных дубликатов - 0
-------------------------------------------------
describe()
```

	count	mean	std	min	25%	50%	75%	m
f0	100000.0	0.002023	1.732045	-8.760004	-1.162288	0.009424	1.158535	7.2382
f1	100000.0	-0.002081	1.730417	-7.084020	-1.174820	-0.009482	1.163678	7.8448
f2	100000.0	2.495128	3.473445	-11.970335	0.130359	2.484236	4.858794	16.7394
product	100000.0	95.000000	44.749921	0.000000	59.450441	94.925613	130.595027	190.0298

```
-------------------------------------------------
corr()
```

	f0	f1	f2	product
f0	1.000000	0.000528	-0.000448	-0.001987

	f0	f1	f2	product
f1	0.000528	1.000000	0.000779	-0.001012
f2	-0.000448	0.000779	1.000000	0.445871

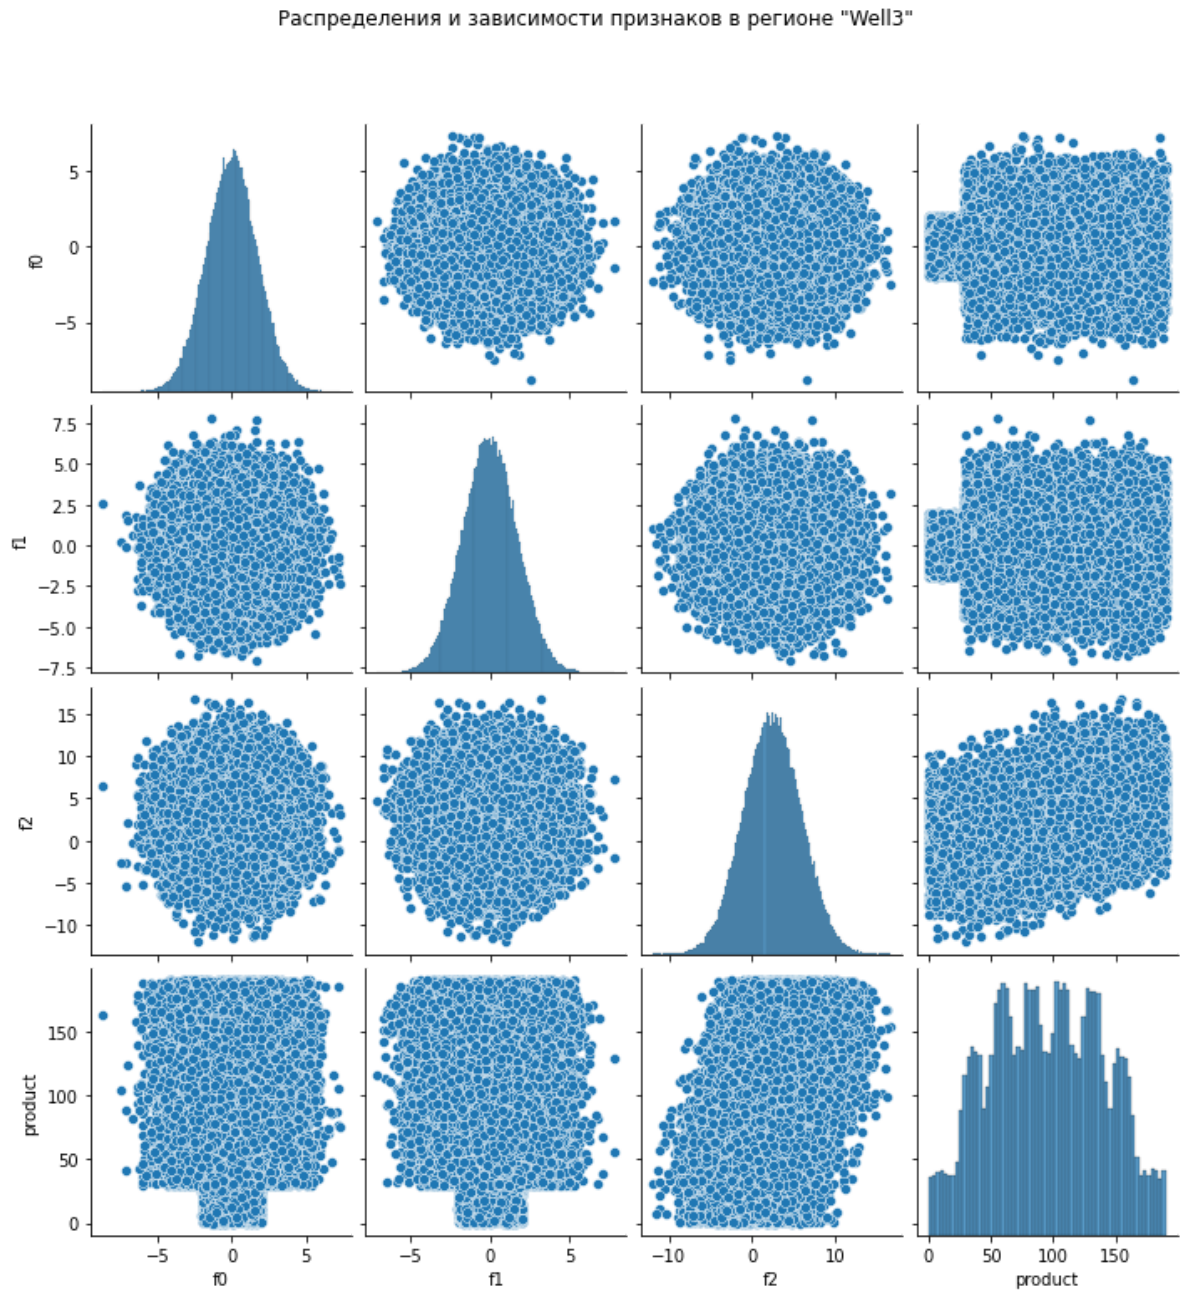

3.2.3.1 Вывод по региону 3

Данные нормальные. Нет пропусков и дубликатов. Не видно сильных аномалий.

4 Обучение и проверка модели

В [17]:

```
# Зададим значения randomState для получения одинаковых результатов
randomState = 42
state = RandomState(randomState)
```

executed in 6ms, finished 12:49:38 2021-08-16

4.1 Регион №1

В [18]:

```
# Выделяем отдельно признаки, отдельно целевой признак
# Столбец id нам также не нужен для обучения
features0 = raw_data0.drop(['product', 'id'], axis=1)
target0 = raw_data0['product']
# features0
```

executed in 17ms, finished 12:49:38 2021-08-16

В [19]:

```
# Делим датаест на обучающую и валидационную выборки
features_train0, features_valid0, target_train0, target_valid0 = train_test_split(
    features0, target0, test_size=0.25, random_state=randomState)
```

executed in 28ms, finished 12:49:38 2021-08-16

В [20]:

```
# Наша модель которая будет делать все предсказания
model = LinearRegression()
```

executed in 4ms, finished 12:49:38 2021-08-16

В [21]:

```
# Функция вывода всей нужной нам информации о модели
def model_specifications(features_train, features_valid, target_train, target_valid):
    model.fit(features_train, target_train)
    predictions_valid = model.predict(features_valid)
    result = mean_squared_error(target_valid, predictions_valid)**0.5 # RMSE на валидац
    print("RMSE модели линейной регрессии на валидационной выборке: {:.2f}".format(resu

    raw_material_stock_pred = predictions_valid.mean()
    raw_material_stock_real = target_valid.mean()
    print('Средний запас предсказанного сырья - {:.2f}'.format(raw_material_stock_pred)
    print('Средний запас реального сырья - {:.2f}'.format(raw_material_stock_real))
    confidence_interval = t.interval(0.95, len(target_valid0), target_valid0.mean(), ta
    print('95%-ый доверительный интервал:', confidence_interval)

```

executed in 13ms, finished 12:49:38 2021-08-16

В [22]:

```
model_specifications(features_train0, features_valid0, target_train0, target_valid0)
```

executed in 38ms, finished 12:49:38 2021-08-16

```
RMSE модели линейной регрессии на валидационной выборке: 37.76
Средний запас предсказанного сырья - 92.40
Средний запас реального сырья - 92.33
95%-ый доверительный интервал: (91.77707015144999, 92.8748425902369)
```

В [23]:

```
# Еще раз разбиваем наш датасет
features_train0, features_valid0, target_train0, target_valid0 = train_test_split(
    features0, target0, test_size=0.25, random_state=randomState)

```

executed in 28ms, finished 12:49:38 2021-08-16

Попробуем нормализовать числовые данные, может это позволит уменьшить RMSE

В [24]:

```
features = ['f0', 'f1', 'f2']
scaler = StandardScaler()
scaler.fit(features_train0[features])
features_train0[features] = scaler.transform(features_train0[features])
# features_train0
```

executed in 32ms, finished 12:49:38 2021-08-16

В [25]:

```
# Сбрасываем индексы, это нам понадобится для дальнейшего бутстрепа
target_valid0.reset_index(drop=True, inplace=True)

```

executed in 4ms, finished 12:49:38 2021-08-16

В [26]:

```
# И повторно запускаем нашу функцию
model_specifications(features_train0, features_valid0, target_train0, target_valid0)
```

executed in 33ms, finished 12:49:38 2021-08-16

```
RMSE модели линейной регрессии на валидационной выборке: 81.12
Средний запас предсказанного сырья - 145.56
Средний запас реального сырья - 92.33
95%-ый доверительный интервал: (91.77707015144999, 92.8748425902369)
```

Нормализация числовых переменных не дала никакого результата, в бальнейшем делать этого не будем

Для удобства запишем все в таблицу

В [27]:

```
results = pd.DataFrame(index=['RMSE на валидационной выборке', 'Средний запас предсказа
                              'Средний запас реального сырья'])
results['Сырые денные регион 1'] = ['37.76', '92.40', '92.33']
results
```

executed in 13ms, finished 12:49:38 2021-08-16

Out[27]:

	Сырые денные регион 1
RMSE на валидационной выборке	37.76
Средний запас предсказанного сырья	92.40
Средний запас реального сырья	92.33

В [28]:

```
# confidence_interval = t.interval(0.95, len(target_valid0), target_valid0.mean(), targ
# confidence_interval
```

executed in 11ms, finished 12:49:38 2021-08-16

4.2 Регион №2

В [29]:

```
features1 = raw_data1.drop(['product', 'id'], axis=1)
target1 = raw_data1['product']
# features1

```

executed in 7ms, finished 12:49:38 2021-08-16

В [30]:

```
features_train1, features_valid1, target_train1, target_valid1 = train_test_split(
    features1, target1, test_size=0.25, random_state=randomState)

target_valid1.reset_index(drop=True, inplace=True)
```

executed in 21ms, finished 12:49:38 2021-08-16

В [31]:

```
model_specifications(features_train1, features_valid1, target_train1, target_valid1)
```

executed in 27ms, finished 12:49:38 2021-08-16

```
RMSE модели линейной регрессии на валидационной выборке: 0.89
Средний запас предсказанного сырья - 68.71
Средний запас реального сырья - 68.73
95%-ый доверительный интервал: (91.77707015144999, 92.8748425902369)
```

Также напомню что у нас странным образом коррелировали столбец со значением f2 и "product" — объём запасов в скважине. Попробуем убрать признаки 'f0', 'f1' и обучить модель без них.

В [32]:

```
features1_1 = raw_data1.drop(['product', 'id', 'f0', 'f1'], axis=1)
```

executed in 10ms, finished 12:49:38 2021-08-16

В [33]:

```
features_train1_1, features_valid1_1, target_train1_1, target_valid1_1 = train_test_spl
    features1_1, target1, test_size=0.25, random_state=randomState)
# features_train1

```

executed in 22ms, finished 12:49:38 2021-08-16

В [34]:

```
model_specifications(features_train1_1, features_valid1_1, target_train1_1, target_vali
```

executed in 18ms, finished 12:49:38 2021-08-16

```
RMSE модели линейной регрессии на валидационной выборке: 1.60
Средний запас предсказанного сырья - 68.72
Средний запас реального сырья - 68.73
95%-ый доверительный интервал: (91.77707015144999, 92.8748425902369)
```

Результат получился плачевный, отклонение стало только больше.

Вернем признаки в датасет по первому региону т.к. на этих данных модель обучилась лучше

В [35]:

```
# features1 = raw_data1.drop(['product', 'id'], axis=1)
```

executed in 4ms, finished 12:49:38 2021-08-16

В [36]:

```
results['Сырые денные регион 2'] = [' 0.89', '68.71', '68.73']
results
```

executed in 13ms, finished 12:49:38 2021-08-16

Out[36]:

	Сырые денные регион 1	Сырые денные регион 2
RMSE на валидационной выборке	37.76	0.89
Средний запас предсказанного сырья	92.40	68.71
Средний запас реального сырья	92.33	68.73

4.3 Регион №3

В [37]:

```
features2 = raw_data2.drop(['product', 'id'], axis=1)
target2 = raw_data2['product']
# features1
```

executed in 8ms, finished 12:49:38 2021-08-16

В [38]:

```
features_train2, features_valid2, target_train2, target_valid2 = train_test_split(
    features2, target2, test_size=0.25, random_state=randomState)

target_valid2.reset_index(drop=True, inplace=True)
```

executed in 23ms, finished 12:49:38 2021-08-16

В [39]:

```
model_specifications(features_train2, features_valid2, target_train2, target_valid2)
```

executed in 24ms, finished 12:49:38 2021-08-16

```
RMSE модели линейной регрессии на валидационной выборке: 40.15
Средний запас предсказанного сырья - 94.77
Средний запас реального сырья - 95.15
95%-ый доверительный интервал: (91.77707015144999, 92.8748425902369)
```

В [ ]:

```

```

В [40]:

```
results['Сырые денные регион 3'] = ['40.15', '94.77', '95.15']
results
```

executed in 12ms, finished 12:49:38 2021-08-16

Out[40]:

	Сырые денные регион 1	Сырые денные регион 2	Сырые денные регион 3
RMSE на валидационной выборке	37.76	0.89	40.15
Средний запас предсказанного сырья	92.40	68.71	94.77
Средний запас реального сырья	92.33	68.73	95.15

4.4 Вывод по блоку

Мы получили 3 основных значения:

- RMSE на валидационной выборке **это корень из среднеквадратичной ошибки наших прогнозов**
- Средний запас предсказанного сырья
- Средний запас реального сырья

Мы видимо что во 2-м регионе у нас отклонение от реальных значений самое маленькое, значит тут наша модель сработала лучше всего. Также видно что средний запас предсказанного сырья не сильно отличается от реального запаса, но средние значения нам очень трудно интерпретировать. С учетом того что мы знает RMSE и видим что в 1-м и 3-м регионе отклонение может достигать почти половины от реальных значений.

Для того чтобы определить наилучший регион для разработок, проведем исследование наших данных техникой Bootstrap.

5 3. Подготовка к расчёту прибыли

5.1 Основные данные

- Бюджет на разработку скважин в регионе — 10 млрд рублей. (budget - Development budget)
- Доход с каждой единицы продукта составляет 450 тыс. рублей (barel - Price per barrel * 1000)

В [41]:

```
budget = 10000000 # считаем в тысячах, поэтому получаем 10 миллионов тысяч
well = 200 #Количество скважин
budget_one = budget / well
barel = 450 #это в тысячах (450 000)

# Well budget - wbudget Бюджет на одну скважину (из расчета что в регионе будет всего 2
# quantity of oil - oilq - минимальный объём запасов в скважине для того чтобы проетк б
```

executed in 5ms, finished 12:49:38 2021-08-16

В [42]:

```
wbudget = budget / 200 #Бюджет на бурение одной скважины
oilq = wbudget / 450
print('Минимальный объём запасов в скважине нужный для того чтобы скважина считалась уд
      '- {:.2f} тысяч бырелей'.format(oilq))
```

executed in 6ms, finished 12:49:38 2021-08-16

```
Минимальный объём запасов в скважине нужный для того чтобы скважина считалас
ь удачной- 111.11 тысяч бырелей
```

5.1.1 Регион №1

In [43]:

```
model.fit(features_train0, target_train0)
predictions_valid0 = model.predict(features_valid0)
result0 = mean_squared_error(target_valid0, predictions_valid0)**0.5 # RMSE на валидац
# print("RMSE модели линейной регрессии на валидационной выборке: {:.2f}".format(result
raw_material_stock_pred0 = predictions_valid0.mean()
raw_material_stock_real0 = target_valid0.mean()
# print('Средний запас предсказанного сырья - {:.2f}'.format(raw_material_stock_pred0))
# print('Средний запас реального сырья - {:.2f}'.format(raw_material_stock_real0))
confidence_interval0 = t.interval(0.95, len(target_valid0), target_valid0.mean(), targe
# print('95%-ый доверительный интервал: {:.2f} : {:.2f}'.format(confidence_interval0[0]
```

executed in 21ms, finished 12:49:38 2021-08-16

Для удобства заносим все в таблицу

In [44]:

```
results2 = pd.DataFrame(index=['RMSE модели линейной регрессии на валидационной выборке
                               'Средний запас реального сырья', '95%-ый доверительный ин
results2['Данные предсказаний регион 1'] = [result0, raw_material_stock_pred0,
                                            raw_material_stock_real0,
                                            '{:.2f} : {:.2f}'.format(confidence_interva
results2
```

executed in 13ms, finished 12:49:38 2021-08-16

Out[44]:

	Данные предсказаний регион 1
RMSE модели линейной регрессии на валидационной выборке	81.116629
Средний запас предсказанного сырья	145.562789
Средний запас реального сырья	92.325956
95%-ый доверительный интервал	91.78 : 92.87

5.1.2 Регион №2

In [45]:

```
model.fit(features_train1, target_train1)
predictions_valid1 = model.predict(features_valid1)
result1 = mean_squared_error(target_valid1, predictions_valid1)**0.5 # RMSE на валидац
# print("RMSE модели линейной регрессии на валидационной выборке: {:.2f}".format(result
raw_material_stock_pred1 = predictions_valid1.mean()
raw_material_stock_real1 = target_valid1.mean()
# print('Средний запас предсказанного сырья - {:.2f}'.format(raw_material_stock_pred1))
# print('Средний запас реального сырья - {:.2f}'.format(raw_material_stock_real1))
confidence_interval1 = t.interval(0.95, len(target_valid1), target_valid1.mean(), targe
# print('95%-ый доверительный интервал:', confidence_interval1)
```

executed in 21ms, finished 12:49:38 2021-08-16

В [46]:

```
results2['Данные предсказаний регион 2'] = [result1, raw_material_stock_pred1,
                                             raw_material_stock_real1, '{:.2f} : {:.2f}

results2
```

executed in 15ms, finished 12:49:38 2021-08-16

Out[46]:

	Данные предсказаний регион 1	Данные предсказаний регион 2
RMSE модели линейной регрессии на валидационной выборке	81.116629	0.89028
Средний запас предсказанного сырья	145.562789	68.712878
Средний запас реального сырья	92.325956	68.725381
95%-ый доверительный интервал	91.78 : 92.87	68.16 : 69.29

5.1.3 Регион №3

В [47]:

```
model.fit(features_train2, target_train2)
predictions_valid2 = model.predict(features_valid2)
result2 = mean_squared_error(target_valid1, predictions_valid2)**0.5 # RMSE на валидаци
# print("RMSE модели линейной регрессии на валидационной выборке: {:.2f}".format(result

raw_material_stock_pred2 = predictions_valid2.mean()
raw_material_stock_real2 = target_valid2.mean()
# print('Средний запас предсказанного сырья - {:.2f}'.format(raw_material_stock_pred2))
# print('Средний запас реального сырья - {:.2f}'.format(raw_material_stock_real2))
confidence_interval2 = t.interval(0.95, len(target_valid2), target_valid2.mean(), targe
# print('95%-ый доверительный интервал:', confidence_interval2)
```

executed in 28ms, finished 12:49:38 2021-08-16

В [48]:

```
results2['Данные предсказаний регион 3'] = [result2, raw_material_stock_pred2,
                                             raw_material_stock_real2, '{:.2f} : {:.2f}
results2
```

executed in 15ms, finished 12:49:38 2021-08-16

Out[48]:

	Данные предсказаний регион 1	Данные предсказаний регион 2	Данные предсказаний регион 3
RMSE модели линейной регрессии на валидационной выборке	81.116629	0.89028	56.447249
Средний запас предсказанного сырья	145.562789	68.712878	94.771024
Средний запас реального сырья	92.325956	68.725381	95.150999
95%-ый доверительный интервал	91.78 : 92.87	68.16 : 69.29	94.60 : 95.71

Как мы видим в регионе номер 2 у нас самое маленькое RMSE, это значит что данные у нас там распределены с меньшим разбросом. При этом средний запас сырья там меньше всего.

5.2 Вывод по блоку

Здесь мы подготовили данные, а именно все ключевые значения для расчётов сохранили в отдельных переменных.

Также мы знаем, что минимальный объём запасов в скважине нужный для того чтобы скважина считалась безубыточный должен составлять - 111.11 тысяч бырелей. Здесь же мы видим что ни один из регионов по этому параметру не подходит. Но нужно не забывать что мы рассматриваем массим из 25 000 скважин. Знаит там есть как хорошие, так и плохие.

Наша основаная задача теперь состоит в том чтобы через Bootstrap найти эти скважины и посчитать все риски.

6 4. Расчёт прибыли и рисков

6.1 Подготовка данных

В [49]:

```
# переводим оббъекты в Series
predictions_valid0 = pd.Series(predictions_valid0)
predictions_valid1 = pd.Series(predictions_valid1)
predictions_valid2 = pd.Series(predictions_valid2)
```

executed in 6ms, finished 12:49:38 2021-08-16

В [50]:

```
# Напишем функцию расчета прибыли

def profit(pred_valid, target_valid, n):
    predictions_valid_sorted = pred_valid.sort_values(ascending=False)
    target_valid_selected = target_valid[predictions_valid_sorted.index][:n]
    result = target_valid_selected.sum() * barel - budget
#     print('Прибыль с 200 лучших скважин составила - {:.2f} тысяч рублей'.format(resul
    return result

# profit(predictions_valid0, predictions_valid0, 200) # для проверки
```

executed in 6ms, finished 12:49:38 2021-08-16

6.1.1 Регион №1

В [51]:

```
# Все значения выручки из нашей выбоки будут храниться в переменной values0 (для каждо
values0 = []

# Производим бутстрап
for i in range(1000):
    target_valid_sub0 = target_valid0.sample(n=500, replace=True, random_state=state)
    pred_valid_subsample0 = predictions_valid0[target_valid_sub0.index]
    predictions_valid_sorted0 = pred_valid_subsample0.sort_values(ascending=False)
    values0.append(profit(predictions_valid_sorted0, target_valid_sub0, 200)) #Добавлен

values0 = pd.Series(values0)

mean0 = values0.mean()
print("Средняя прибыль: {:.2f}".format(mean0))

lower0 = values0.quantile(.025)
upper0 = values0.quantile(.975)

# # Определяем 95%-й доверительный интервал
# interval0 = t.interval(0.95, len(values0), values0.mean(), values0.sem())

# print(interval0)
print('95% доверительный интервал в регионе (тысяч руб.) - {:.2f} - {:.2f}'.format(lowe
```

executed in 1.95s, finished 12:49:40 2021-08-16

```
Средняя прибыль: 330813.18
95% доверительный интервал в регионе (тысяч руб.) - -221514.71 - 851390.64
```

В [52]:

```
# Расчитываем риск убытков
risk_of_loss0 = values0[values0 < 0].count()/1000
print('Риск убытков в регионе 1: {:.2%}'.format(risk_of_loss0))
```

executed in 6ms, finished 12:49:40 2021-08-16

```
Риск убытков в регионе 1: 12.10%
```

Для удобства запишем все в таблицу

В [53]:

```
results3 = pd.DataFrame(index=['Средняя прибыль в регионе после Bootstrap (тысяч руб.)'
                               '95% доверительный интервал в регионе (тысяч руб.)',
                              'Риск убытков в регионе в %'])
results3['Данные предсказаний регион 1'] = ['{:.2f}'.format(mean0),
                                            '{:.2f} : {:.2f}'.format(lower0, upper0),
results3
```

executed in 12ms, finished 12:49:40 2021-08-16

Out[53]:

	Данные предсказаний регион 1
Средняя прибыль в регионе после Bootstrap (тысяч руб.)	330813.18
95% доверительный интервал в регионе (тысяч руб.)	-221514.71 : 851390.64
Риск убытков в регионе в %	12.10%

6.1.2 Регион №2

В [54]:

```
values1 = []

for i in range(1000):
    target_valid_sub1 = target_valid1.sample(n=500, replace=True, random_state=state)
    pred_valid_subsample1 = predictions_valid1[target_valid_sub1.index]
    predictions_valid_sorted1 = pred_valid_subsample1.sort_values(ascending=False)
    values1.append(profit(predictions_valid_sorted1, target_valid_sub1, 200))

values1 = pd.Series(values1)

mean1 = values1.mean()
print("Средняя прибыль: {:.2f}".format(mean1))

# interval1 = t.interval(0.95, len(values1), values1.mean(), values1.sem())

# print(interval1)
lower1 = values1.quantile(.025)
upper1 = values1.quantile(.975)

print('95% доверительный интервал в регионе (тысяч руб.): {:.2f} - {:.2f}'.format(lower
```

executed in 1.98s, finished 12:49:42 2021-08-16

```
Средняя прибыль: 511530.22
95% доверительный интервал в регионе (тысяч руб.): 91700.56 - 921455.67
```

В [55]:

```
risk_of_loss1 = values0[values1 < 0].count()/1000
print('Риск убытков в регионе 1: {:.2%}'.format(risk_of_loss1))
```

executed in 11ms, finished 12:49:42 2021-08-16

```
Риск убытков в регионе 1: 0.60%
```

В [56]:

```
results3['Данные предсказаний регион 2'] = ['{:.2f}'.format(mean1),
                                             '{:.2f} : {:.2f}'.format(lower1, upper1),
results3
```

executed in 17ms, finished 12:49:42 2021-08-16

Out[56]:

	Данные предсказаний регион 1	Данные предсказаний регион 2
Средняя прибыль в регионе после Bootstrap (тысяч руб.)	330813.18	511530.22
95% доверительный интервал в регионе (тысяч руб.)	-221514.71 : 851390.64	91700.56 : 921455.67
Риск убытков в регионе в %	12.10%	0.60%

6.1.3 Регион №3

В [57]:

```
values2 = []

for i in range(1000):
    target_valid_sub2 = target_valid2.sample(n=500, replace=True, random_state=state)
    pred_valid_subsample2 = predictions_valid2[target_valid_sub2.index]
    predictions_valid_sorted2 = pred_valid_subsample2.sort_values(ascending=False)
    values2.append(profit(predictions_valid_sorted2, target_valid_sub2, 200))

values2 = pd.Series(values2)
lower2 = values2.quantile(0.025)

mean2 = values2.mean()
print("Средняя прибыль: {:.2f}".format(mean2))
# interval2 = t.interval(0.95, len(values2), values2.mean(), values2.sem())

# print(interval2)
lower2 = values2.quantile(.025)
upper2 = values2.quantile(.975)

print('95% доверительный интервал в регионе (тысяч руб.): {:.2f} - {:.2f}'.format(lower
```

executed in 1.79s, finished 12:49:44 2021-08-16

```
Средняя прибыль: 408545.68
95% доверительный интервал в регионе (тысяч руб.): -120624.87 - 960859.44
```

В [58]:

```
risk_of_loss2 = values0[values2 < 0].count()/1000
print('Риск убытков в регионе 1: {:.2%}'.format(risk_of_loss2))
```

executed in 7ms, finished 12:49:44 2021-08-16

```
Риск убытков в регионе 1: 7.50%
```

В [59]:

```
1 results3['Данные предсказаний регион 3'] = ['{:.2f}'.format(mean2),
2                                              '{:.2f} : {:.2f}'.format(lower2, upper2),
3 results3
```

executed in 16ms, finished 12:49:44 2021-08-16

Out[59]:

	Данные предсказаний регион 1	Данные предсказаний регион 2	Данные предсказаний регион 3
Средняя прибыль в регионе после Bootstrap (тысяч руб.)	330813.18	511530.22	408545.68
95% доверительный интервал в регионе (тысяч руб.)	-221514.71 : 851390.64	91700.56 : 921455.67	-120624.87 : 960859.44
Риск убытков в регионе в %	12.10%	0.60%	7.50%

6.2 Вывод

Мы брали по 500 случайных скважин каждого региона, далее сортировали их в порядке убывания по количеству сырья, потом отбирали из них 200 лучших, считали среднее значение и записывали его в переменную. Так мы сделали 1000 раз и получили результаты:

1. Средняя прибыль в регионе номер 2 будет самой большой
2. Мы получили 95% доверительный интервал **в этом интервале с 95% вероятностью будет находиться среднее значение прибыли**
3. мы также посчитали % убыточных скважин.

Исходя из полученных результатов отвечаем на наши главные вопросы:

1. **Построить модель для определения региона, где добыча принесёт наибольшую прибыль.** - это регион номер 2
2. **Проанализировать возможную прибыль и риски.** - наименьшие риски убыточных скважин - так же 2-й регион

Делаем вывод что бурить нужно во 2-м регионе!